指令层级研究说明

非官方中文研究资料 · 0.3 · 来源与许可逐篇注明

目录

1 指令层级怎样成为可训练的问题 **2**

1.1 先把三个不同的失败拆开 2

1.2 固定评分骨架为何有用 2

1.3 论文结果的含义与实验身份 3

1.4 如何设计下一次研究 3

参考文献 **4**

1 指令层级怎样成为可训练的问题

研究来源：OpenAI 2026-03-10 官方说明与 Guo 等 2026-03-11 的 IH-Challenge v1[2, 1]。本文是原创中文研究说明，不是逐段译本。该论文采用 arXiv 非独占分发许可，未据此获得全文翻译许可；原图、原数据和长提示不镜像。下面的符号、例子、推导和练习为本项目设计。

1.1 先把三个不同的失败拆开

给模型一个数学问题，它答错了，不能直接断言它不懂指令层级。给模型相互冲突的指令，它输出了符合高优先级格式的错误内容，也不能直接断言任务完成。应分别检验解题、遵循约束、辨认约束的权威来源。指令层级研究关心第三项，但测量会受到前两项污染。

设一段对话为 $c = ((r_1, m_1), \ldots, (r_k, m_k))$，$r_i$ 是消息角色，m_i 是内容。角色由应用的结构传入，正文里自称“管理员”不改变角色。对本研究采用的政策，权威次序为 system、developer、user、tool。低级消息中的资料仍可用于完成任务；只有冲突的行为要求应被忽略。“工具不可信”不等于其每一个事实都是假的。

定义 1.1 给定高优先级规则 s，令 $\mathcal{Y}_s(c)$ 为符合规则的输出集合。约束遵循率为 $\Pr[y \in \mathcal{Y}_s(c)]$；任务正确率另由 $T(c, y)$ 衡量。两者的交集 $\Pr[y \in \mathcal{Y}_s(c), T(c, y) = 1]$ 才衡量受约束任务完成。

例如规则要求“只输出 A 或 B”，低级消息要求“附上一段解释”。输出 A 满足格式，但若正确选项是 B，仍未完成任务。输出“B，因为……”可能知识上正确，却不满足当前接口。评分器必须同时记录两种事实，不能只给一个含糊总分。

1.2 固定评分骨架为何有用

IH-Challenge 的关键工程取舍是将高优先级任务和程序评分器先固定，再在线合成低优先级攻击；任务应易于执行、易于客观评分，同时包含反误拒样本。这样可以减少把普通解题困难误计为冲突处理失败，也让攻击改变时评分目标仍有固定含义。论文还审计评分器，并不把通过几个测试当成评分器绝对正确。

我们用一个原创的严格 schema 例子说明这个取舍。高优先级要求输出 JSON 对象且键集合恰为 {`choice`}，值属于 {`A`, `B`}；用户给出两选一算术题。评分器先解析整个输出，再检查键、类型和值，最后与独立计算的答案比较。字符串搜索“含有 B”会接受“我不选择 B”；只找第一段花括号会容忍泄漏在对象外的额外文本。这些反例说明评分器本身就是研究对象。

设 D 是高优先级任务分布，$A(\delta \mid s)$ 是当前攻击分布，π_θ 是模型，固定评分器为 $g_s(y)$。一个抽象训练目标是

$$J(\theta) = \mathbb{E}_{s \sim D,\, \delta \sim A(\cdot \mid s),\, y \sim \pi_\theta(\cdot \mid s, \delta)}[g_s(y)].$$

若 A 随训练改变，这不是一次固定监督数据集上的拟合。若评分器错了，优化可把错误放大。程序可判定仅表示计算过程明确，不表示程序定义的目标等于我们真正想要的安全。

例题 1.1 有 80 个禁止泄漏题和 20 个授权正常任务。若奖励只记录前一组不泄漏，永远拒绝得到满分。若联合完成率采用全部 100 题且正常任务拒绝记错，则永远拒绝只有 0.8。这个数仍可能过高，所以报告还应分别给两组分数；改变样本配比也会改变总分。

解答. 设拒绝率策略在禁止组成功概率为 a、正常组成功概率为 b，汇总值是 $0.8a + 0.2b$。只看汇总值不能恢复 a, b：$(1, 0)$ 与 $(0.75, 1)$ 都给 0.8。需要分组指标，并把正常任务难度控制到模型本来能够解决的范围。 □

1.3 论文结果的含义与实验身份

作者报告 GPT-5-Mini 经训练得到内部实验模型 GPT-5-Mini-R，16 项评价平均稳健率由 84.1% 到 94.1%，指定安全评价中的不安全行为由 6.6% 到 0.7%。这是该论文协议中的作者结果，不能移植成当前公开产品的错误率，也不能证明任意新攻击都被抵御。官方说明中的聊天偏好指标还存在小幅下降；“能力基本保持” 应结合每项指标理解。本文未调用该内部模型，未复现这些前沿分数。

本项目的 `v03_research.py` 用明确来源的符号策略模拟 240 个正常案例及 120 个攻击案例。来源盲策略在 120 个案例都偏离用户目标；加执行器权限检查后，80 个越权提案被阻止，仍有 40 个许可内的语义错误。关键词拒绝挡住攻击，却误拒 120 个正常案例。理想来源路由器在这个被完全定义的有限任务上全部正确。这些是实际程序结果，证明了该程序的机制差异；它没有语言理解，不能据此宣称 LLM 已被防护。

另一个实际诊断使用两份固定版本 SmolLM2-135M 权重，包含六道 system/user 冲突题。两选项续写评分的准确率均为 3/6，严格单字母生成格式的通过率为零。完整输出保留供检查。这里没有 tool 消息，只有很小的题集，没有自适应攻击或训练；它不能复现 IH-Challenge，但让我们看到格式、选择概率和任务完成确实是三个不同测量。

1.4 如何设计下一次研究

可做的下一步是保持事实任务不变，只交换同一条命令所在的结构角色，比较成对输出。先在无冲突条件验证任务本来可解，再加入冲突；另设看起来危险但实际授权的正常题，测误拒。攻击集按作者、模板、目标分别留出，防止只记住关键词。评分器应有解析歧义、嵌套对象、额外文本等负例。若允许模型采取行动，执行器在模型之外独立审查操作、资源和目的地，语言输出的分数之外还要审计真正发生的状态变化。

习题 1.1 一个模型不泄漏率为 0.99，正常任务完成率为 0.50；另一模型两项分别为 0.95, 0.90。若禁止与正常题各占一半，谁的联合得分高？为什么仍不能只报这个值？

解答. 分别是 0.745 和 0.925，第二个更高。但在泄漏代价很高的系统中，任务比例不是损失比例；还须报告两项、按后果加权，并在部署分布评估，不能把平均数当安全保证。 □

习题 1.2 若评分器只检查输出没有秘密字符串，模型输出另一个用户的隐私会不会被发现？

解答. 未必。评分器的可判定范围只是指定字符串。这是测量覆盖缺口，不是随机种子问题。扩充威胁模型、独立访问控制与审计目标，才能形成对该类风险的证据。 □

参考文献

[1] Chuan Guo 等. IH-Challenge: A Training Dataset to Improve Instruction Hierarchy on Frontier LLMs. 2026-03-11. https://arxiv.org/abs/2603.10521.

[2] OpenAI. Improving instruction hierarchy in frontier LLMs. 2026-03-10. https://openai.com/index/instruction-hierarchy-challenge/.

浏览器注入研究说明

非官方中文研究资料 · 0.3 · 来源与许可逐篇注明

目录

1 浏览器提示词注入：从文本风险到状态变化 **2**

1.1 代理让错误多了一个出口 2

1.2 自适应攻击的分母是什么 2

1.3 把防线拆成可检验条件 3

1.4 我们的实际权限与误拒实验 3

1.5 一个可复核浏览器研究协议 3

参考文献 **4**

1 浏览器提示词注入：从文本风险到状态变化

来源为 Anthropic 2025-11-24 的官方研究说明 [1]。以下为原创分析、模型与实验设计，不是全文翻译；未取得开放改编许可的原文和图不镜像。讨论该发布日期的实验，不将其当成 2026 年现行产品保证。

1.1 代理让错误多了一个出口

聊天模型可以回答错误。浏览器代理还可能把回答转成点击、表单、文件访问或发送动作。外部页面原本只是任务资料；如果其文字被当成行动命令，资料就跨越了权威边界。仅把某个危险词删除不能建立边界，因为攻击可以改写措辞，而正常任务也可能需要阅读危险内容。

用 (o_t, a_t, s_t) 表示第 t 步的观察、动作和外部状态。代理先依据观察和历史生成提案 $a_t = \pi(o_{\le t}, a_{<t})$，执行器再决定是否允许并得到 $s_{t+1} = F(s_t, a_t)$。需要分别检验：模型是否形成错误提案、执行器是否执行越权动作、最终状态是否满足用户目标。挡住发送到外部地址，并不意味着没有把错误信息写进一个获授权的草稿。

定义 1.1 能力许可用三元组 $(\text{operation}, \text{resource}, \text{scope})$ 表示，例如读指定公开文档、写指定草稿。权限谓词 $C(a)$ 判断动作是否落在许可内；语义目标谓词 $T(s)$ 判断最终状态是否完成用户任务。$C(a) = 1$ 不推出 $T(F(s, a)) = 1$。

给一个原创例子：用户授权整理公开会议安排。代理被页面文字诱导把会议时间改成错误值，仍只写入获授权草稿。操作权限全部合法，任务仍失败。另一个提案读取不相关私密文件，则可由执行器直接拒绝。前者需要来源与事实校验，后者需要权限约束，两种防线测量不同事件。

1.2 自适应攻击的分母是什么

官方报告使用每个环境最多 100 次尝试的自适应攻击，并报告该协议中的约 1% 攻击成功率；系统同时涉及模型训练、输入分类与干预、专家红队。这个结果属于整个评估配置，不能只归因于一个模型，也不能解释成任意单次恶意网页只有 1% 危险。

命题 1.2 *若每次攻击独立且有同样成功概率 p，N 次中至少一次成功的概率为 $q_N = 1 - (1-p)^N$。不需要独立时仍有 $\Pr(\bigcup_i E_i) \le \sum_i \Pr(E_i)$，但后式通常不是精确值。*

证明. 独立时全部失败概率为 $(1-p)^N$，取补事件。一般情况使用并集上界；事件可能重叠，所以把概率相加只能得上界。 □

例题 1.1 若单次独立失败概率为 0.001，100 次至少一次失败约为 0.0952。若某协议的 100 次汇总成功率为 0.01，在独立同分布的额外假设下才可反解 $p = 1 - 0.99^{1/100} \approx 0.0001005$。真实攻击会根据之前结果调整，既不独立也不同分布，所以不能用这个反解估计实际单次风险。

这里还要明确单位：每个环境是否重置、每次是否重新抽任务、成功判定看输出还是实际状态、攻击者能修改哪些观察、是否能看模型轨迹。缺少这些信息，两个 ASR 数字即使相近也不一定可比。

1.3 把防线拆成可检验条件

模型训练可以改变提案分布；分类器可以给观察附风险标记；干预可改变代理后续行为；执行器可以拒绝超出许可的操作。设恶意观察为 M，模型提出越权动作是 P，执行器放行为 X。当 $\Pr(M) > 0$ 且 $\Pr(P \mid M) > 0$ 时，实际越权概率为

$$\Pr(P \cap X \mid M) = \Pr(P \mid M) \Pr(X \mid P, M).$$

这是条件概率恒等式，不需要两道防线独立。若 $\Pr(P \mid M) = 0$，越权概率直接为零，无需定义第二因子。若只测 $\Pr(P \mid M)$，没有评价执行器；若只测实际执行，没有知道模型是否在不停提出危险动作。声称“两道防线各降低十倍，合起来一百倍”需要证明条件错误率，而不能将边际错误率机械相乘。

输入扫描若漏检某观察，并不意味着执行必然出错。输入扫描若命中，也可能误拒正常资料。应同时记录真攻击执行率、正常任务完成率、误拒、延迟和费用；任务全拒绝给零 ASR，却没有可用代理。

1.4 我们的实际权限与误拒实验

`results/v03-research/metrics.json` 保留全部四种符号策略的结果。对 120 个攻击案例，来源盲策略执行 80 个越权动作且产生 120 个语义失败；加许可执行器后越权执行变成零，但语义失败仍有 40 个。关键词拒绝没有语义攻击成功，却把正常完成率降到 0.5。理想来源路由器在有限案例中保持正常完成并抵御全部攻击。这个最后结果由模拟器的完整规则保证，不能移植为真实语言理解能力。

多步模拟另设每步基础错误率 0.08，错误后状态吸收，八步成功的理论值为 $0.92^8 \approx 0.5132$，10,000 条实际轨迹的成功率为 0.5150。加入指定恢复与误拒机制后，实际成功率为 0.6569。这些数来自实际执行，但错误率和独立假设是人工规定；它说明多步任务需要测轨迹而非只平均局部准确率，未测任何公司代理的真实行为。

1.5 一个可复核浏览器研究协议

先建立沙盒页面与本地文件，所有收件人和目的地均为模拟对象。冻结正常任务集合、允许动作集合、成功判定和攻击预算。正常任务覆盖只读与写草稿；攻击覆盖目标改变、角色伪装和无关动作诱导。把攻击者可见信息写进协议，再比较无防线、仅模型提示、仅执行器、完整系统四组。测试过程保存每步观察、提案、许可判断和状态差异，最后由独立程序判定目标是否实现。

该设计避免把“模型说自己抵御了攻击”当证据。对实际系统，还应报告跨网页模板、跨任务与跨攻击者的留出结果；真实网页里的脚本、视觉和动态加载超出这套文本沙盒。第一次小研究可以只研究文本，但标题和结论必须写出这个范围。

习题 1.1 所有越权执行都被阻止，能否得出代理任务安全完成？给一个许可内失败例子。

解答. 不能。代理可把来自恶意页面的错误地址写到授权报告，动作在许可内而事实错误。权限验证与目标、事实核验应分别测量。 □

习题 1.2 在 200 个独立环境中零次攻击成功，能否声称真实成功率是零?

解答. 不能。若各环境独立同分布，真实成功率 q 下观察零次的概率为 $(1-q)^{200}$。解 $(1-q)^{200}=0.05$，得到单侧 95% 上界约 0.0149。若环境相关或被选择过，这个统计范围也未必有效。 □

参考文献

[1] Anthropic. Mitigating the risk of prompt injections in browser use. 2025-11-24. https://www.anthropic.com/research/prompt-injection-defenses.

R1 比较阅读说明

非官方中文研究资料 · 0.3 · 来源与许可逐篇注明

目录

1 怎样读 R1 的奖励、推理轨迹与证据 **2**

1.1 从目标概率到奖励梯度 2

1.2 GRPO 的两个粒度不能混算 2

1.3 可验证任务为什么提供了新的训练条件 2

1.4 进步来自新能力还是选择概率 3

1.5 练习与下一步阅读 3

参考文献 **3**

1 怎样读 R1 的奖励、推理轨迹与证据

阅读对象是 2025-09-17 的 Nature 正式论文 [1]，其完整正文、Methods 与 Extended Data 译文另卷提供。该版 CC BY 4.0 不自动适用于另一个 arXiv 版本或独立补充文件。本说明以原创推导把论文放到基础学习、DPO、测试时计算与可验证训练的共同问题链中。

1.1 从目标概率到奖励梯度

预训练给出了 $\pi_\theta(y \mid x)$，自回归分解为各 token 条件概率的乘积。监督微调用固定示范的负对数概率训练；奖励训练则先从当前或旧策略采样，再依据回答是否满足目标调整分布。若输出具有固定支持，在其上 $\pi_\theta(y \mid x) > 0$ 且关于 θ 可微，$r(x, y)$ 不显式依赖 θ，并且可以交换求导与求和，则

$$\nabla_\theta \mathbb{E}_{y\sim\pi_\theta}[r(x,y)] = \sum_y r(x,y)\pi_\theta(y \mid x)\nabla_\theta \log \pi_\theta(y \mid x) = \mathbb{E}[r(x,y)\nabla_\theta \log \pi_\theta(y \mid x)].$$

若奖励依赖生成出的文本，通过评分器产生一个数，这个恒等式并不要求对评分程序求导。数学推导说明怎样提高有奖励输出的概率；它没有说明奖励为什么忠实地衡量了推理质量。

对任意只依赖输入 x 的基线 $b(x)$，$\mathbb{E}[b(x)\nabla \log \pi] = b(x)\nabla \sum_y \pi(y \mid x) = 0$。减基线可改变方差而不改变该精确期望。采样组均值包含当前样本，是否无偏还须看具体估计器；这正是教材分开推导组内与留一基线的原因。

1.2 GRPO 的两个粒度不能混算

Nature Methods 式 (1) 以整条输出策略比 $\pi_\theta(o_i \mid q)/\pi_{\theta_{\text{old}}}(o_i \mid q)$ 写示意目标。token 实现又可在每个时间步用比值 ρ_{it} 并对裁剪项平均。整序列比是 token 比的乘积；对乘积裁剪和对每个比值分别裁剪后平均一般不相同。读者应在论文版本、实现与本地简化之间明确粒度，而不是把相似符号当成同一算法。

例题 1.1 两 token 的旧条件概率分别为 $0.4, 0.5$，新条件概率为 $0.8, 0.25$，则两 token 比为 $2, 0.5$，整序列比为 1。取正优势 $A = 1$、裁剪区间 $[0.8, 1.2]$，序列裁剪项为 1；token 裁剪目标的均值为 $(1.2 + 0.5)/2 = 0.85$。

解答. PPO 型项是 $\min(\rho A, \text{clip}(\rho)A)$，第二个 token 的原比 0.5 比裁剪后 0.8 更小，故仍取 0.5。这不是两个公式算错，而是两种目标不同。 □

1.3 可验证任务为什么提供了新的训练条件

数学答案和程序测试让部分任务有廉价、重复可用的反馈；同一输入可生成许多轨迹，探索不同策略。这里可验证的对象可能只是最终答案或有限测试，并非整段推理证明。答案正确可能来自巧合，测试通过也可能过拟合。形式证明由核验器检查每个推导步骤，具有更强的逻辑证书，但自动形式化及题意对应又是额外问题。AlphaProof 译文把这一点具体化；不能把形式核验结论扩展到任意自然语言研究。

R1 正式论文比较无冷启动的 R1-Zero 与多阶段 R1，并报告强化学习中轨迹长度、自我检查等现象。它们是可观察文本和性能现象，不是意识或全部内部推理过程的直接记录。多阶段流程同时改变数据、训练目标与模型状态；一个最后榜单分数不能识别每项的独立因果贡献，应读对应消融、评价样本与采样预算。

1.4 进步来自新能力还是选择概率

把基础模型在一道题上生成正确解答的概率记为 p。若独立采样 k 次、存在完美选择器，则 pass@k 为 $1-(1-p)^k$。训练把 p 从 0.05 提到 0.30 时，单次成功大幅提高；足够大的基础模型采样预算也可能暴露已有的解题路径。这两个事实不冲突。

关于 RLVR 能力边界的研究 [2] 使用 pass@k、覆盖与生成似然比较基础和训练后分布。其意义是提醒我们同时测高概率能力和可达的正确轨迹；有限 k 没有采到某轨迹，不能证明其概率严格为零。反过来，基础模型偶尔能生成正确答案，也不能说训练没有实际收益。学习者应把“可达范围”“固定预算可靠性”和“跨分布迁移”作为三个不同目标。

本项目的有限动作奖励实验实际更新指定策略，并记录了错误验证器下 best-of-N 随预算增大反而降低真正确率的案例。它检验奖励和选择偏差的数学机制，没有训练 671B R1，更没有用微型实验声称复现其长链推理。下一次可行研究是固定小模型和题库，比较更新前后 pass@1、固定 k 的覆盖、输出长度和分布外题目；测试题不可参与挑模型或奖励规则。

1.5 练习与下一步阅读

阅读顺序是教材的后训练推导、DPO 全译的闭式策略变换、R1 Methods 与实验、Snell 全译的预算分配，再到 CaT 的无参考监督。每篇都问：奖励从哪里来？哪个对象被优化？选择器能访问哪些信息？预算与比较对象是否匹配？这些问题比仅记住方法缩写更能帮助独立设计研究。

习题 1.1 若 $p = 0.1$，完美验证器下十次独立采样成功概率是多少？若所有十次输出完全相同呢？

解答. 独立时为 $1 - 0.9^{10} \approx 0.6513$；完全相同时仍为 0.1。多样性和相关性是预算收益的必要测量，不能只报采样次数。 □

习题 1.2 训练后的正确回答更长，能否说明长回答导致正确？如何得到更有用的证据？

解答. 不能；难题、模型状态、训练筛选可能同时影响长度与正确性。应在可控任务上固定模型和输入，改变可用预算或训练条件，报告成对结果及截断如何影响内容；还要区别真正额外计算与无效重复文本。 □

参考文献

[1] DeepSeek-AI 等. DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning. Nature 645, 633–638, 2025-09-17. https://www.nature.com/articles/s41586-025-09422-z.

[2] Yang Yue 等. Does Reinforcement Learning Really Incentivize Reasoning Capacity in LLMs Beyond the Base Model?. v5 2025-11-24; NeurIPS 2025. https://arxiv.org/abs/2504.13837v5.