以计算作为教师

非官方中文研究资料 · 0.3 · 来源与许可逐篇注明

目录

1 计算即教师：将推理计算转为无参考监督 2

1.1 摘要 . . . 2
1.2 1 引言 . . . 2
1.3 2 相关工作 . . . 4
1.4 3 计算即教师 . . . 5
1.5 4 实验 . . . 7
1.6 5 讨论 . . . 11
1.7 致谢 . . . 11
1.8 附录 A 结果表与补充结果 . . . 11
1.9 附录 B 合成与全部轨迹不一致的例子 . . . 16
1.10 附录 C 合成输出分析 . . . 16
1.11 附录 D CaT 何时停止学习 . . . 17
1.12 附录 E GRPO 概述 . . . 18
1.13 附录 F 提示 . . . 18
1.14 附录 G 评分细则样例 . . . 22
1.15 附录 H 超参数 . . . 23
1.16 附录 I 实验细节 . . . 24
1.17 译者术语表 . . . 25

参考文献 26

1 计算即教师：将推理计算转为无参考监督

原作：Dulhan Jayalath[1,†]、Shashwat Goel[2,3,†]、Thomas Foster[1,5]、Parag Jain[5]；
Suchin Gururangan[4,†]、Cheng Zhang[5]、Anirudh Goyal[5]、Alan Schelten[5]. 单位：[1] 牛津大学；[2]ELLIS Institute Tübingen；[3] 马克斯 · 普朗克智能系统研究所；[4]Anthropic；[5]Meta Superintelligence Labs. [†] 表示该工作在 Meta Superintelligence Labs 完成. 通信地址：dulhan@robots.ox.ac.uk、agi@meta.com、alanschelten@meta.com.

指定原文为 https://arxiv.org/abs/2509.14234v3，v3 日期 2026 年 5 月 9 日，首次提交日期 2025 年 9 月 17 日. 指定 PDF 首页面内日期为 2026 年 5 月 12 日，而同版本 HTML 的内部日期显示 2026 年 8 月 24 日；源文件使用排版时日期宏，二者均与固定的 arXiv 版本日期分开记录. 该版本官方页面的许可证链接指向 CC BY 4.0：https://creativecommons.org/licenses/by/4.0/. 本译稿由 ai-self-study contributors 以机器辅助方式译制，非官方译本. 改动包括完整中文翻译、授权固定版式重排、交叉引用与图表编号适配、术语表及单独标记的译者说明. 原书目元数据、模型与程序标识符、XML 标签和必要输出标记保留原文. 论文原图或由原作者 TikZ 代码导出的矢量图逐图署名，图内英文标注保留. 未复制原稿的公司标志、文档类或字体文件. 会议版本仅用于版本信息对照，本文翻译和许可依据不与它混用. 下文“我们”均指原作者.

注 译者说明：伪参考是由模型生成的监督估计，不等于外部真值. 二元评分细则由模型提议并由模型判别，仍可能有遗漏、错误和共同偏差. 数学领域的答案匹配奖励只检验与伪参考的一致性；医疗领域的实验分数也不能直接当作临床真实性或安全性的证明. 以下正文忠实保留原作的结论和数值，这些说明与正文分开.

1.1 摘要

后训练没有真值时，学习信号来自哪里？我们表明，推理计算本身可以充当监督. 通过生成并行采样轨迹并将它们转化为参考估计，模型可以不依赖人类标签而学习；关键是，这甚至适用于医疗指导等不存在程序化检查器的不可验证领域. 我们把框架称为“计算即教师”（Compute as Teacher，CaT），它把并行采样轨迹的推理时计算转化为 RL 训练监督. 框架有两个组件：参考估计把轨迹聚合成伪参考答案，奖励推导把伪参考转化为 RL 奖励. 对前者，我们探索一种称为合成的简单方法，但框架接受任意聚合器；对后者，我们为不可验证领域提出自提出评分细则，即从伪参考生成、由大语言模型判别器计分的二元、可审计标准. HealthBench 上，CaT 训练模型达到或超过推理时聚合质量，而测试时计算减少 9 倍. 在这里，CaT 也可与使用专家医师标注的学习方式竞争，相对初始策略最高改善约 30%. 框架自然扩展到可验证奖励，在 MATH-500 的测试时 RL 设置下达到最佳已有基线表现，展示跨两类领域的即插即用能力.

1.2 1 引言

为获得专门技能而后训练大语言模型，通常依赖带标签参考答案的监督微调 [17, 34]，或依赖程序化检查器提供可验证奖励的强化学习. 这种检查器只适用于数学、代码等形式正确性可计算的狭窄领域 [14, 25]. 同时，许多有价值任务也没有标注参考答案. 在答案具有定性性质的不可验证场景中，如临床或生活方式指导 [2]、自由对话 [21] 和创意写作 [18]，可能存在多个有效答案，专家可能意见不同，确定性规则检查难以实施. 因而实践者常退回难以扩

展的标注流程，或仅靠判别器反馈：让另一大语言模型为自由输出给粗粒度分数，尽管这种方式存在不一致、偏好冗长回答和奖励投机等已知问题.

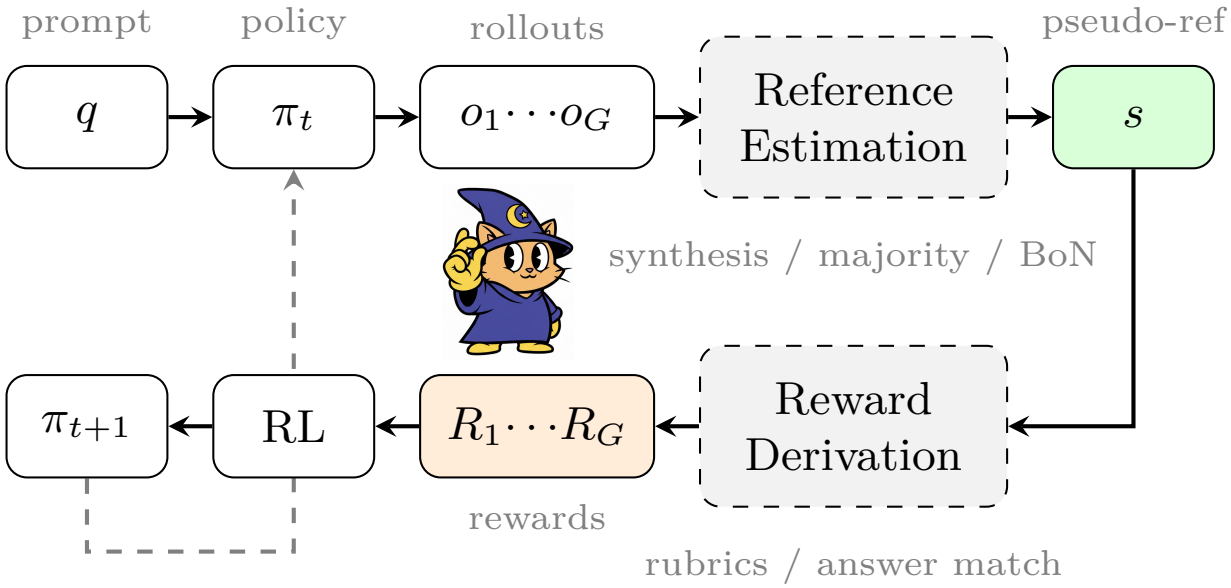


图 1.1: CaT 框架. 策略 π_t 为提示 q 生成 G 条轨迹. 参考估计通过合成、多数投票或 best-of-N，将它们聚合为伪参考 s. 奖励推导依据 s 为每条轨迹计分：可验证领域使用答案匹配，不可验证领域使用自提出评分细则. 奖励驱动 RL，更新策略. 原图：Dulhan Jayalath 等，完整作者名单见文首，CC BY 4.0；由原作者 TikZ 导出，英文标注保留.

本文转而提出一个简单问题：推理计算能否替代缺失的监督？

计算即教师. 我们回答“能”. CaT 用参考估计和奖励推导两个组件，把推理计算转成监督. 关键是，并行轨迹对模型的不确定性进行采样，因为它们恰好在模型不确定之处分歧. 一条轨迹可能有正确中间步骤，另一条有正确最终答案，第三条有有用验证；总体集合比单条包含更多信息. 参考估计把分散信息聚合为一个伪参考，奖励推导依据它为轨迹计分，以用于 RL. 框架不依赖具体聚合方法：多数投票、best-of-N 等选择策略找回最佳轨迹，生成策略则组合各轨迹片段，构建新回答. 我们探索简单的合成策略，让冻结策略条件于轨迹集合构建新回答，但任意聚合器都可接入同一奖励推导机制. GRPO 等组式 RL 已经为优势估计生成并行轨迹，因此参考估计增加的开销很小.

不可验证领域的无参考奖励. 奖励推导因领域而异. 数学、代码等可验证场景中，简单检查轨迹答案是否与伪参考一致. 更难的是没有这种检查的不可验证领域. 我们提出另一项关键贡献——自提出评分细则，让模型生成刻画伪参考的二元标准，如“建议咨询医疗专业人员”“指出患者对心律失常的担忧”. 独立大语言模型判别器逐项检查，奖励为满足标准的比例. 由此，不依赖真值也能为每条轨迹给奖励，在不可验证领域进行无参考 RL.

有效原因的直观解释. 轨迹从模型不确定性采样，分歧揭示了模型犹疑之处. 合成迫使模型检查分歧，依据证据选择一个观点或构建调和方案；选择方法只能挑一个已有答案. 不可验证领域的细则问“回答是否满足标准 X”，而非“回答好不好”；分解把模糊判断变成细粒度二元检查的求和，使验证更容易. 关键是，从伪参考自提出细则后，CaT 无需任何人类标注参考答案，就能为不可验证领域的轨迹提供奖励.

实用性. 框架实用且即插即用，无需人类标签、领域专用验证器，并复用标准 RL 已花费的组采样计算. CaT 把推理时聚合的收益摊入模型权重，在达到或超过聚合表现的同时，把每次查询的测试时计算最多减少 9 倍. 训练后策略回答质量还常超过初始聚合伪参考，并持续改进，直到轨迹趋于相似回答. 我们在 Gemma 3 4B、Qwen 3 4B、Llama 3.1 8B 三个模型家族，以及不可验证 HealthBench 和可验证 MATH-500 上验证.

CaT 连接多条研究路线. 它像自训练 [22, 23, 27, 28] 和知识蒸馏 [10] 一样，从模型生成监督学习，但通过调和多个样本产生目标，而非信任单个自标签. 它像多数投票、best-of-N 等测试时扩展方法一样利用并行轨迹，但通过 RL 把改善摊入权重. 相比大语言模型充当判别器的奖励 [44]，细则评分提供分解、具体的标准，缓解不稳定和偏见 [5, 8]. 最后，CaT 把学习扩展到没有形式检查器的领域，补充程序化验证 [14].

贡献：

1. 不可验证 RL 的自提出评分细则：将判断分解为二元标准的奖励机制，让没有程序化检查器的领域也能进行无参考 RL.
2. 计算即教师：通过参考估计和奖励推导，把推理计算转成监督的一般范式，合成是其中一种有效参考估计器.
3. 全面经验研究：三个模型在 HealthBench 与 MATH-500 上取得增益，训练模型用少 9 倍计算达到或超过推理时质量.

文章安排. 第2节讨论相关工作；第3节形式化框架和自提出细则；第4节给出实验设置；第4.2节给出结果、消融与分析；第5节讨论局限、未来方向并总结.

1.3 2 相关工作

无参考微调. 自生成监督在大语言模型训练中历史悠久. Constitutional AI[3] 用自我修订的生成结果训练，Self-Instruct[33] 生成并筛选自身的指令遵循数据，Quiet-STaR[40] 在没有参考轨迹时学习产生推理 token. 它们针对无害性、指令遵循和推理等专门能力. CaT 更一般：只要模型能生成多样轨迹，且不可验证领域中的细则判断可靠，就支持无人工参考的 RL.

无参考 RL. 近期工作探索无真值标签的 RL. TTRL[46] 用多数投票共识作数学伪标签，Absolute Zero[41] 在自行提出的数学和代码问题上自博弈. 这些方法有效，但局限于正确性可由程序检查的领域. 另一条路线最小化熵或最大化自确定性 [43, 1, 19, 6, 15]. Wen 等 [35] 依据互可预测性为多项选择答案评分. 这些方法具有判别性质，只选择或评分已有输出. CaT 可用任一方法作参考估计器，也能超越选择；如果采用合成，它可构建采样集合分布之外的伪参考. 更重要的是，CaT 通过自提出细则扩展到不可验证领域，先前方法尚未用于这种设置；我们将其改为基线时，表现不及 CaT（第3.1节）.

测试时扩展. 并行轨迹长期用于改善推理表现. 多数投票或自一致性 [32] 选最常见答案；best-of-N 依信心、困惑度或大语言模型判断选择 [44]. 它们提升准确率，却不把收益写入权重，每次部署都承担完整 G 条轨迹成本. CaT 用同样轨迹生成 RL 监督，把推理计算摊入训练. 训练后模型以 $1/G$ 测试时成本达到或超过聚合质量，因此大部分计算在训练中一次性花费，而非推理时反复支付.

不可验证 RL. 无法程序化验证时如何产生奖励？已有方法假定可访问参考答案. VeriFree[45]、JEPO[31] 和 RLPR[38] 计算参考答案在模型推理链条件下的概率. Rubrics as Rewards（RaR）[8] 从参考答案构建评价细则，再

由大语言模型判断评分，展示细则奖励优于直接评分. 我们继承此认识，但完全消除参考依赖：CaT 从轨迹估计的伪参考自提出细则. 推理计算生成伪参考，伪参考生成细则，细则生成奖励；流程没有人类标注进入.

1.4 3 计算即教师

CaT 通过参考估计和奖励推导两个组件将推理计算转为监督，图1.1展示框架. 给定提示 q，当前策略 π_t 生成 G 条并行轨迹 $o_{1:G}$. 它们在模型不确定之处不同，因而采样其不确定性. 参考估计聚合为单个伪参考回答 s，用作监督目标. 奖励推导依据 s 为每条 o_i 产生 RL 奖励 $R(o_i; s)$.

框架不依赖具体聚合方法. 多数投票和 best-of-N 从已有轨迹选一个 s；合成等生成策略条件于全部轨迹构建新的 s，可能组合分散在集合中的正确片段. 本文经验探索合成，但奖励推导机制，尤其不可验证领域的自提出细则，可以配合任意参考估计策略.

记号. q 为提示，o_i 为采样轨迹，s 为伪参考，$\mathcal{R} = \{r_j\}$ 为由二元标准组成的细则，π_t 为第 t 步当前策略，π_0 为冻结锚点即初始策略，π_J 为细则计分的判别模型.

3.1 参考估计

参考估计把 G 条轨迹聚合成一个伪参考 s，任意聚合策略均兼容，包括：

- 多数投票：s 为 $o_{1:G}$ 中最常见的最终答案 [46]，只适用于可比较答案的可验证领域.
- Best-of-N：对某评分函数 f，令 $s = \arg\max_{o_i} f(o_i)$；可使用模型困惑度 [1]、信心启发式 [15] 或判别器分数.
- 合成：冻结锚点 π_0 条件于轨迹集合，按某提示生成新回答，调和其中的信息.

选择最多找回最佳轨迹. 合成可构建组合多个正确片段的回答，潜在地超过全部轨迹. 我们聚焦合成，并在第4.4节与选择基线比较.

合成. 给定 $o_{1:G} \sim \pi_t(\cdot \mid q)$，锚点生成

$$s \sim \pi_0(\cdot \mid p_{\text{syn}}, o_{1:G}). \tag{1.1}$$

p_{syn} 指示模型将轨迹调和成一个更好的回答；完整提示见附录F. 两个设计选择值得解释. 第一，为简便，我们从锚点输入中省去原提示 q，消融见附录A.4. 第二，使用冻结初始策略而非当前策略，使探索与估计解耦：π_t 经 RL 探索改进，π_0 提供参考估计，只优化 π_t.

合成何时有帮助？轨迹在模型犹疑之处分歧. 一条可能有正确中间步骤但结论错误，另一条可能通过有缺陷推理得到正确答案. 合成检查分歧，整合互补证据，如一条的正确步骤和另一条的有效检查. 实验中，合成在 5–15% 问题上不同于多数答案，也可不同于全部轨迹却仍正确（第4.5节）. 这提示它进行某种结构化生成调和，而非只改写答案并充当选择器.

3.2 奖励推导

给定伪参考 s，为 RL 导出每条轨迹的奖励，机制依领域而异.

3.2.1 可验证领域

正确性可以程序检查时，奖励与伪参考一致：

$$R_{\text{ver}}(o; s) = \mathbf{1}[\texttt{answer}(o) = \texttt{answer}(s)]. \tag{1.2}$$

数学问题中，`answer` 提取最终方框表达式，再检查字符串等价. 这有意保持简单，因为此领域的复杂性在参考估计而非奖励推导.

3.2.2 不可验证领域

同等优质答案可有大量表达方式，规则方法不实用，因此没有这种检查器. 直接让大语言模型打 1–10 分等朴素替代方案，存在提示间不一致、偏好冗长或流畅风格、易受奖励投机影响等已充分记录的问题 [44, 2]. 我们改为将判断分解成从伪参考生成、分别计分的自提出二元细则（图1.2）.

生成细则. 锚点依据伪参考生成 $\mathcal{R} = \{r_1, \ldots, r_n\}$：

$$\mathcal{R} \sim \pi_0(\cdot \mid p_{\text{rub}}, s). \tag{1.3}$$

每个 r_j 是刻画 s 重要属性的二元、可验证陈述. 提示要求至少 5 条具体标准，完整生成提示见附录F.

细则计分. 独立判别模型 π_J 检查轨迹是否满足每条标准：

$$R_{\text{rub}}(o; \mathcal{R}) = \frac{1}{n} \sum_{j=1}^{n} \mathbf{1}[\pi_J(o, r_j) = \text{“yes”}]. \tag{1.4}$$

奖励为按判别器判断满足标准的比例.

为何用细则？ 分解有三个优点：可靠性——“是否建议专业咨询”比“回答好不好”更容易一致地判断；可审计性——可查看满足或失败的标准，便于调试分析，而直接分数不透明；减轻表面形式偏差——无论措辞、长度、格式如何，都可满足“建议改变生活方式”，因此有助于奖励内容而非风格.

例子. 用户询问轻度高血压管理，合成产生建议饮食改变、运动与医疗随访的伪参考，锚点生成细则：承认用户所述症状；建议饮食、运动等生活方式改变；建议咨询医疗服务提供者；避免确定性诊断；语气有同理心且适当. 若轨迹满足第 1、2、3、5 项而不满足第 4 项，则得 $R = 4/5 = 0.8$.

3.3 训练

我们用组相对策略优化 GRPO[25] 实现 CaT，但奖励形式兼容每个提示采样多条轨迹的任意策略梯度方法. 每个提示采样 G 条轨迹，以组均值计算优势：

$$\widehat{A}_i = \frac{R(o_i; s) - \overline{R}_G}{\sigma_G}. \tag{1.5}$$

其中 $\overline{R}_G = G^{-1} \sum_j R(o_j; s)$，$\sigma_G$ 为标准差. 策略通过带截断和相对初始策略 KL 正则的替代目标更新，细节见附录E.

GRPO 已为优势估计生成 G 条轨迹，CaT 复用它们，只增加一次合成调用以生成 s；不可验证领域另加一次细则生成调用，再进行 nG 次判别调用. 合成调用成本相当于多生成一条轨迹；nG 次判别可并行，输出只有是 / 否等很少 token，费用较低. 实际上，相比生成 G 条轨迹，参考估计和奖励推导只增加适度开销.

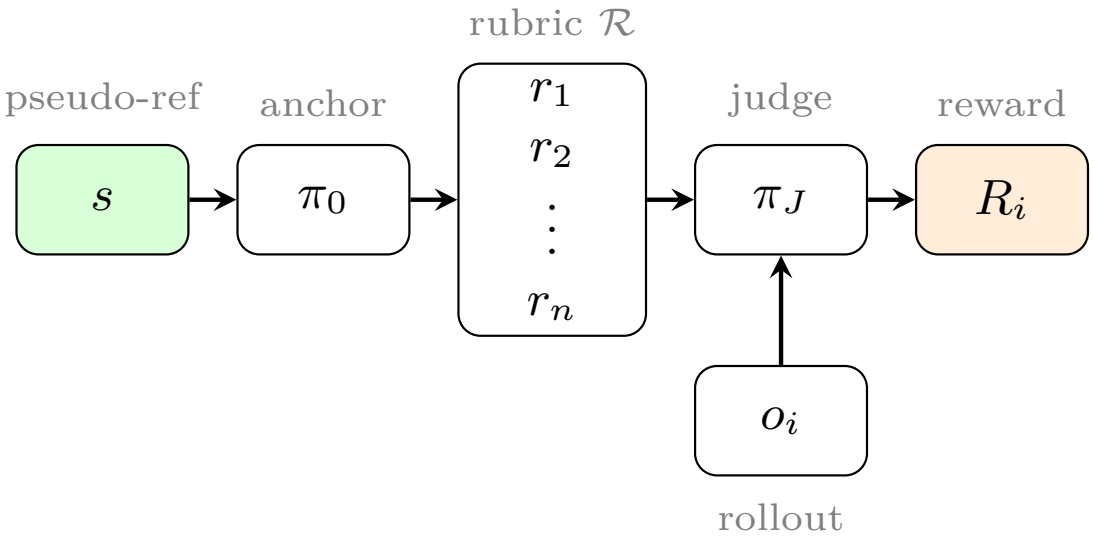


图 1.2: 不可验证领域基于细则的奖励. 锚点 π_0 从伪参考 s 生成二元是 / 否标准 $\mathcal{R} = \{r_1, \ldots, r_n\}$. 判别器逐项为轨迹 o_i 计分，奖励为满足的比例. 原图：Dulhan Jayalath 等，完整名单见文首，CC BY 4.0；由原作者 TikZ 导出，英文标注保留.

训练循环. 下列算法概括一次迭代：采样、估计伪参考、导出奖励，再用 GRPO 更新. **原文算法 1：CaT 的一次训练步骤**

1. 输入：当前策略 π_t、锚点 π_0、判别器 π_J、提示 q、参考估计器 Aggregate.
2. 采样 $o_{1:G} \sim \pi_t(\cdot \mid q)$；估计 $s \leftarrow \text{Aggregate}(o_{1:G})$，例如合成或多数投票.
3. 若 q 可验证，对每个 $i = 1, \ldots, G$，令 $R_i \leftarrow \mathbf{1}[\texttt{answer}(o_i) = \texttt{answer}(s)]$.
4. 否则，生成 $\mathcal{R} \sim \pi_0(\cdot \mid p_{\text{rub}}, s)$；对每个 i，令 $R_i \leftarrow |\mathcal{R}|^{-1} \sum_{r \in \mathcal{R}} \mathbf{1}[\pi_J(o_i, r) = \text{“yes”}]$.
5. 计算 $\widehat{A}_i = (R_i - \overline{R}_G)/\sigma_G$；用 $\{(o_i, \widehat{A}_i)\}_{i=1}^{G}$ 经 GRPO 更新策略.

推理时使用. 参考估计也可仅用于推理、不训练 RL. 从初始策略为提示生成 G 条轨迹，估计伪参考并返回它. 这以至少 G 倍推理计算带来即时准确率收益，但没有转入权重，每次部署都付全额成本. CaT 将收益摊入训练，训练后策略只产生一个输出，就可达到相似或更好质量. 实验中，它以少 9 倍测试时计算达到或超过推理时合成.

1.5 4 实验

我们主要评价以合成作为参考估计的 CaT 训练框架，其次单独评价不训练时的合成，隔离各组件收益. 实验回答：CaT 能否改进初始策略，并以更低测试成本达到或超过推理时合成？自提出细则能否在不可验证领域提供有效奖励？合成与选择基线的参考估计相比如何？

4.1 设置

数据集. HealthBench[2] 含医师与用户的 5000 段自由医疗对话，是有多个有效定性答案、无程序检查器的不可验证领域. 留出 500 段有医师设计评价细则的对话测试，其余用于无参考训练与验证. MATH-500[9] 含 500 道竞赛数学

题，最终答案可程序检查. 遵循 TTRL[46]，在同一 500 题上训练测试，训练不访问任何参考标签，属于测试时训练设置. HealthBench 是主要试验场，因为不可验证领域是更困难、尚未解决的问题；MATH-500 展示框架无需修改可跨领域类型泛化，是统一即插即用框架，而非不可验证领域专用方法.

模型. 评价三个 4–8B 规模指令调优模型家族：Gemma 3 4B Instruct[13]、Qwen 3 4B Instruct[37] 和 Llama 3.1 8B Instruct[7]. 合成与细则生成的锚点均为训练前初始策略；细则计分使用 GPT-4o[12] 作为判别器. 除非另有说明，CaT 的参考估计始终使用合成.

评价. HealthBench 按留出医师细则报告回答准确率，并如基准论文一样由 GPT-4o 计分. MATH-500 报告最终答案正确比例. 始终取 $G = 8$. 误差棒是跨测试样本计算的标准误. 超参数和更多细节见附录H、I.

4.2 主要结果

图1.3概括主要发现. 所有模型与两个领域中，CaT 均改进初始策略；相对未训练策略，HealthBench 最高改善约 30%，MATH-500 约 33%.

达到或超过推理时合成. HealthBench 上 CaT 一致优于推理时合成. MATH-500 二者相近，Gemma 和 Llama 中 CaT 稍好，Qwen 中稍差. 关键是，在 HealthBench 的泛化归纳设置中，CaT 用少 9 倍测试时计算达到这种表现：训练策略只产生一个回答，推理时合成要 8 条轨迹加一次生成.

改进持续到轨迹收敛. 更好策略生成信息更丰富轨迹，产生更好伪参考，进一步改进策略. 全部模型中观察到这一动态：6 个模型—数据集对中，5 个超过自己的教师信号，即初始合成伪参考. 足够训练后，轨迹趋于一致，留给合成调和的分歧减少，伪参考相对单条轨迹的增量信号递减（附录D）. 这与 RL 微调中已知的熵坍缩一致 [39, 30].

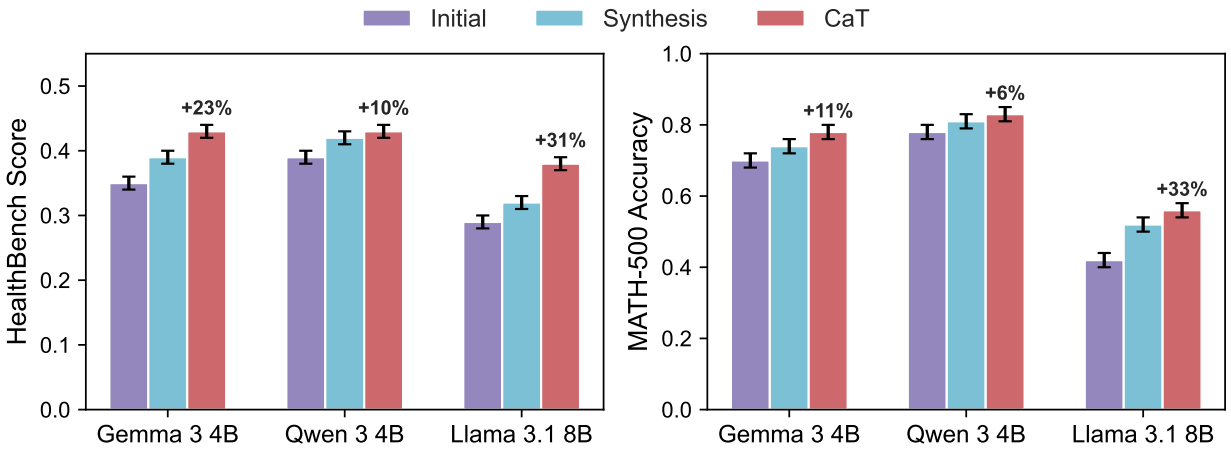


图 1.3: CaT 相对初始策略最多改善 30%. 它以少 9 倍测试时计算达到或超过推理时合成. 在 HealthBench 上，Gemma 和 Llama 的 CaT 优于合成，Welch t 检验 $p < 0.05$. 原图：Dulhan Jayalath 等，CC BY 4.0；英文标注保留.

4.3 不可验证领域的自提出细则

核心挑战是奖励推导，因此比较：从伪参考生成的自提出细则、HealthBench 人工标注医师细则这一理想基线，以及直接由大语言模型判断轨迹是否匹配伪参考的模型直接评判.

图1.4左显示，自提出细则在三个模型上均优于模型直接评判，在其中两个上与医师细则相近. 无人工输入时，模型生成的评价标准有时与专家设计一样有效. 粗粒度判断脆弱可能解释直接评判表现较差. 图右比较 CaT 与在合成伪参考上监督微调的 CaT-SFT. CaT 在全部模型上获胜，常有明显差距，如 Llama 的 0.38 对 0.28. 这与有限数据下 RL 比 SFT 更好泛化的先前发现一致 [4, 8].

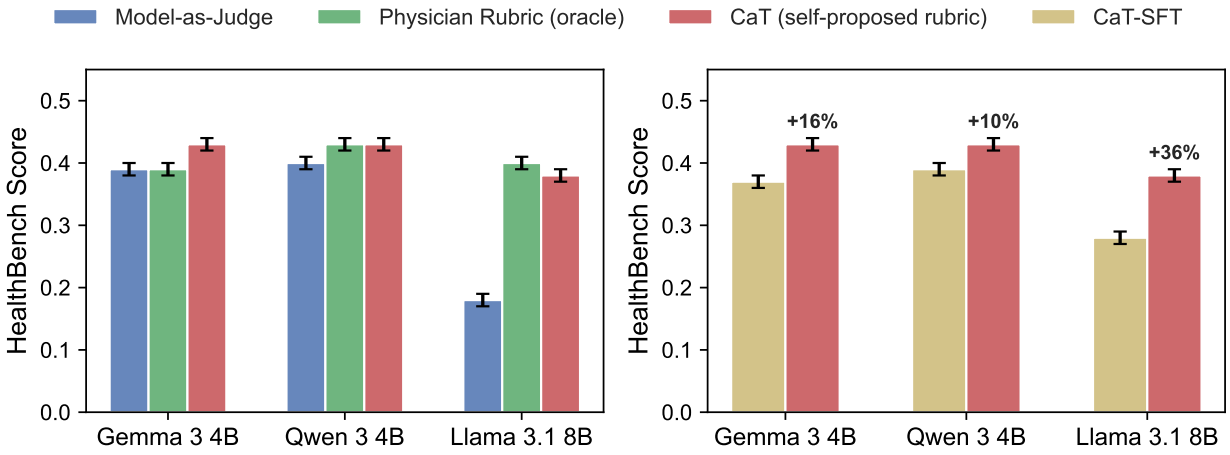


图 1.4: 左：自提出细则可比于医师细则，并优于模型直接评判（$p < 0.05$）. 右：基于细则奖励的 RL 优于在合成参考上 SFT. CaT 在所有情形均优于 CaT-SFT（$p < 0.05$）. 显著性用 Welch t 检验. 原图：Dulhan Jayalath 等，CC BY 4.0；英文标注保留.

4.4 参考估计：合成与选择

在不训练 RL 的推理时比较合成与选择基线，以识别适合框架的参考估计策略. 基线包括：单样本；在 G 条轨迹中选最常见最终答案的多数投票，仅可验证领域使用；策略选择自身最佳回答的 Self-BoN；最低困惑度选择 [1]；以及互可预测性 [35]，即选择条件于其他全部轨迹时概率最高的回答.

图1.5显示各模型与数据集的推理表现. 合成在不可验证 HealthBench 上优于全部基线，在 MATH-500 上也达到或超过它们，支持跨类型直接使用. 附录A.1还给出其他选择方法的部分 RL 结果. 最老的 Llama 3.1 8B 相对选择的合成收益较小，却有最大 RL 收益. 合成要求识别并解决轨迹差异，较弱模型可能因元认知推理基础能力较低而困难.

4.5 合成与选择有何不同

选择最多找回最佳轨迹，合成等生成方法可构建潜在超过最佳轨迹的新回答. 本节分析何时、如何体现这一差别.

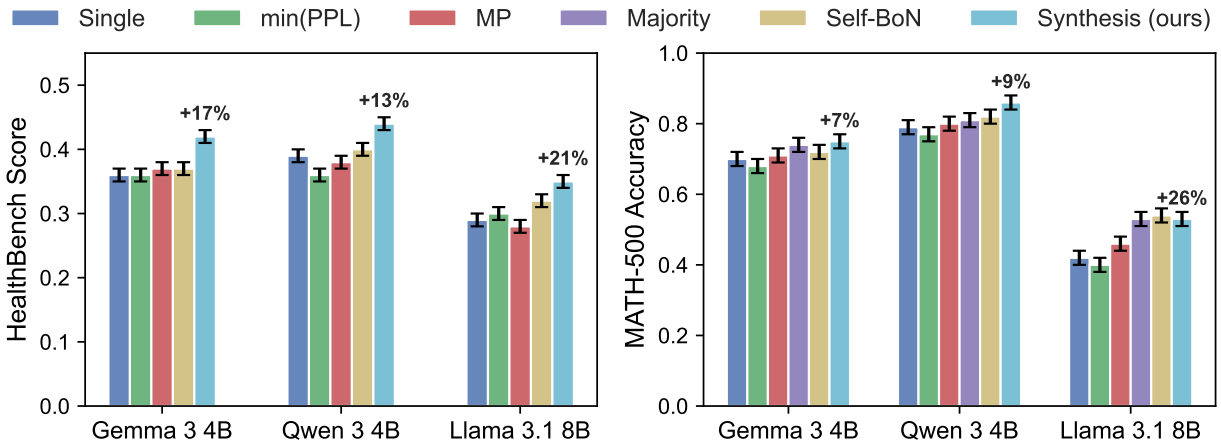


图 1.5: 不可验证 HealthBench 上，合成在推理时超过选择基线. 可验证 MATH-500 上也能与最佳方法竞争，支持跨领域即插即用. 改善百分比相对单样本. HealthBench 上相对次佳方法的全部合成增益，都经 Welch t 检验达到 $p < 0.05$. 原图：Dulhan Jayalath 等，CC BY 4.0；英文标注保留.

表1.1显示，合成在 5–7% 问题上与多数投票不同，在 7–10% 上与 Self-BoN 不同. 不同之处的正确率显著高于机会水平：相对多数投票为 82–86%，相对 Self-BoN 为 70–82%. 因此分歧平均提供改善表现的答案，超出选择方法所能触及的范围.

约 1% 的问题中，全部轨迹错误而合成产生正确答案. 选择不可能做到，因为答案在采样集合分布之外. 附录B给出互补算术错误的实例，合成整合正确推理步骤同时避免错误.

也可能怀疑合成只受益于额外生成一个样本，而未使用轨迹. 为检验这一点，在 Qwen 3 4B、MATH-500 上比较条件于 8 条与 1 条轨迹：单轨迹上下文时，仅从 0.79 小幅改善到 0.80；8 条时，明显优于多数投票，0.85 对 0.81. 因而合成可能调和跨轨迹信息，而非充当独立样本. 附录C对输出的分析提供进一步证据.

表 1.1: 合成可能与选择方法不一致，并在不一致时给出正确答案. MATH-500 上 7 个种子的平均结果；平均而言，这些分歧有助于改进.

比较	p(不一致)	p(正确 | 不一致)
Qwen 3 4B		
Synth. vs Maj. vote	4.8%	**86.3**%
Synth. vs Self-BoN	6.5%	**81.7**%
Gemma 3 4B		
Synth. vs Maj. vote	7.4%	**81.5**%
Synth. vs Self-BoN	9.9%	**70.2**%

1.6 5 讨论

局限与未来工作. CaT 要求初始模型能生成有用轨迹，并在使用合成时连贯地调和它们；基础表现较低的模型收益较小. 框架继承 RL 的已知限制：策略改善时轨迹多样性减少，合成可调和的分歧变少，轨迹收敛后增益进入平台期. 表现还可能依赖判别器能力（附录A.3）. 未来可通过更好采样或探索奖励 [29] 生成更多样轨迹. 参考估计和奖励推导可独立改进：学习的聚合器可能优于提示式合成；部分得分、层级标准、信心加权等细粒度细则可能提高评分准确性与粒度. 除单轮回答，还可扩展到推理轨迹、多轮对话或智能体行动轨迹.

结论. 我们提出把推理计算转为监督的 CaT. 并行轨迹采样模型不确定性，参考估计聚合为伪参考，奖励推导转为 RL 奖励. 框架不依赖聚合方式，合成是一种强选项，多数投票与 best-of-N 也可用. 核心贡献是在不可验证领域支持无参考 RL：自提出细则无需人工标注提供稳定奖励. HealthBench 上，细则表现相近于医师设计，CaT 相对初始策略最多改善 30%，训练模型以少 9 倍测试时计算达到或超过聚合质量. 因而计算可在训练中花一次，替代推理中反复支付. 可验证 MATH-500 上表现与其他方法一样好，展示跨类型即插即用. 当参考答案稀少、昂贵、有争议甚至未知时，CaT 提供实用后训练框架. 人工标注成为专门领域瓶颈时，从推理计算学习提供了一条可能的路径.

1.7 致谢

按姓名字母顺序，我们感谢 Joseph Brennan 协助处理细则数据，Lovish Madaan 提供多种技术帮助，Nicola Cancedda 对机构审批流程给予反馈，Stéphane Collot 指导细则生成，Yonatan Gideoni 评论本文草稿，以及 Yunzhen Feng 提供一般技术建议. DJ 在本研究时是 Meta 实习生，并得到 EPSRC Autonomous Intelligent Machines and Systems（AIMS）博士训练中心的 AWS Studentship 支持，项目号 EP/S024050/1.

1.8 附录 A 结果表与补充结果

表1.2、1.3、1.4和1.5将正文图中的结果转写为表格.

表 1.2: CaT 与初始策略的比较. 最佳值加粗，次佳值加下划线.

模型	方法	HealthBench 分数	MATH-500 准确率
Gemma 3 4B	初始策略	0.35 ± 0.01	0.70 ± 0.02
	合成	$\underline{0.39} \pm 0.01$	$\underline{0.74} \pm 0.02$
	CaT	$\mathbf{0.43} \pm 0.01$	$\mathbf{0.78} \pm 0.02$
Qwen 3 4B	初始策略	0.39 ± 0.01	0.78 ± 0.02
	合成	$\underline{0.42} \pm 0.01$	$\underline{0.81} \pm 0.02$
	CaT	$\mathbf{0.43} \pm 0.01$	$\mathbf{0.83} \pm 0.02$
Llama 3.1 8B	初始策略	0.29 ± 0.01	0.42 ± 0.02
	合成	$\underline{0.32} \pm 0.01$	$\underline{0.52} \pm 0.02$
	CaT	$\mathbf{0.38} \pm 0.01$	$\mathbf{0.56} \pm 0.02$

表 1.3: 不同评分细则与评判方法的分数. 最佳值加粗，次佳值加下划线.

模型	方法	HealthBench 分数
Gemma 3 4B	自提出评分细则	$\mathbf{0.43} \pm 0.01$
	模型直接评判	$\underline{0.39} \pm 0.01$
	医师评分细则	$\underline{0.39} \pm 0.01$
Qwen 3 4B	自提出评分细则	$\mathbf{0.43} \pm 0.01$
	医师评分细则	$\mathbf{0.43} \pm 0.01$
	模型直接评判	0.40 ± 0.01
Llama 3.1 8B	自提出评分细则	$\underline{0.38} \pm 0.01$
	医师评分细则	$\mathbf{0.40} \pm 0.01$
	模型直接评判	0.18 ± 0.01

表 1.4: CaT 与 CaT-SFT 的 HealthBench 分数. 最佳值加粗.

模型	方法	HealthBench 分数
Gemma 3 4B	CaT	$\mathbf{0.43} \pm 0.01$
	CaT-SFT	0.37 ± 0.01
Qwen 3 4B	CaT	$\mathbf{0.43} \pm 0.01$
	CaT-SFT	0.39 ± 0.01
Llama 3.1 8B	CaT	$\mathbf{0.38} \pm 0.01$
	CaT-SFT	0.28 ± 0.01

表 1.5: 各模型与基准上的推理时方法比较. 最佳结果加粗，次佳结果加下划线.

模型	方法	HealthBench 分数	MATH-500 准确率
Gemma 3 4B	单样本	0.36 ± 0.01	0.70 ± 0.02
	min(PPL)	0.36 ± 0.01	0.68 ± 0.02
	MP	0.37 ± 0.01	0.71 ± 0.02
	多数投票	不适用	$\underline{0.74} \pm 0.02$
	Self-BoN	$\underline{0.37} \pm 0.01$	0.72 ± 0.02
	合成	$\mathbf{0.42} \pm 0.01$	$\mathbf{0.75} \pm 0.02$
Qwen 3 4B	单样本	0.39 ± 0.01	0.79 ± 0.02
	min(PPL)	0.36 ± 0.01	0.77 ± 0.02
	MP	0.38 ± 0.01	0.80 ± 0.02
	多数投票	不适用	0.81 ± 0.02
	Self-BoN	$\underline{0.40} \pm 0.01$	$\underline{0.82} \pm 0.02$
	合成	$\mathbf{0.44} \pm 0.01$	$\mathbf{0.86} \pm 0.02$
Llama 3.1 8B	单样本	0.29 ± 0.01	0.42 ± 0.02
	min(PPL)	0.30 ± 0.01	0.40 ± 0.02
	MP	0.28 ± 0.01	0.46 ± 0.02
	多数投票	不适用	$\underline{0.53} \pm 0.02$
	Self-BoN	$\underline{0.32} \pm 0.01$	$\mathbf{0.54} \pm 0.02$
	合成	$\mathbf{0.35} \pm 0.01$	$\underline{0.53} \pm 0.02$

A.1 与选择方法进行 RL 的比较

表1.6中，CaT 在 RL 下优于选择基线，正如合成在推理时的表现一样，因为合成提供更好的监督信号.

表 1.6: 与使用选择方法进行 RL 的基线比较，模型为 Llama 3.1 8B.
多数投票在定性答案领域不适用，故 HealthBench 留为不适用.

方法	HealthBench	MATH-500
CaT	**0.38** $\pm$ 0.01	**0.56** $\pm$ 0.02
多数投票-RL	不适用	0.53 $\pm$ 0.02
min(PPL)-RL	0.33 $\pm$ 0.01	0.51 $\pm$ 0.02

A.2 条件于伪参考生成细则

表1.7对细则生成条件消融：条件于伪参考 s 优于只条件于问题 q，相对改善 12%. 参考估计花费的计算不仅改善监督目标，也改善导出细则的质量.

表 1.7: 条件于伪参考的细则优于只条件于问题的细则. Llama 3.1 8B 的结果.

细则生成条件	**HealthBench 分数**
伪参考 s	0.38 $\pm$ 0.01
问题 q （仅）	0.34 $\pm$ 0.01

A.3 判别器敏感性

表1.8报告使用不同规模判别模型时的 HealthBench 结果；评价基准的判别器保持相同. 更强判别器带来一定表现改善，可能因为细则判断更准确.

表 1.8: 对判别模型的敏感性. 更强判别模型产生更好的 CaT 表现.
策略为 Llama 3.1 8B，使用 Llama 3 70B 评价.

细则判别模型	**HealthBench 分数**
Llama 3.1 8B	0.48
Llama 3.3 70B	0.54

A.4 合成聚合器中省去问题

合成步骤没有在估计器提示中包含任务提示或问题，因为 Gemma 3 4B 在 MATH-500 的预先推理实验中，加入它没有造成差别，变化为 +0.004. 排除任务提示使设置更简单，对表现没有有意义的影响，也有助于确保聚合器不直接尝试答题、沦为另一条独立轨迹.

注 译者注：正文称 Qwen 的 CaT 在 MATH-500 上稍低于推理时合成，但原附录表1.2列出合成 0.81、CaT 0.83；表1.5的推理方法比较又列出合成 0.86. 本译稿分别照原文与原表保留，不擅自判定或更正哪一处代表作者最终意图. 此外，HealthBench 不同判别器设置的分数不能脱离各自评价设置直接混比.

1.9 附录 B 合成与全部轨迹不一致的例子

与全部轨迹不一致的情形发生于所有模型. 以下是 Gemma 3 4B 在 MATH-500 中发现的若干例子之一.

> 题目：对所有复数 $z \neq i$，令 $F(z) = (z+i)/(z-i)$，并对所有正整数 n 令 $z_n = F(z_{n-1})$. 已知 $z_0 = 1/137 + i$，求 z_{2002}.

全部轨迹都未给正确答案，出现了计算错误. 第二条轨迹的一个例子没有正确完成除法：

$$\text{错误：}\quad z_1 = \frac{\frac{1}{137}+2i}{\frac{1}{137}} = \frac{1+2i\cdot 137}{137} = \frac{1+274i}{137},$$
$$\text{正确：}\quad z_1 = \frac{\frac{1}{137}+2i}{\frac{1}{137}} = \frac{1+274i}{1} = 1+274i.$$

另一个例子中，第六条轨迹在与第二条近似相同的位置，不知为何用 137 与 1 反复乘除，犯下多个计算错误：

$$\text{错误：}\quad z_1 = \frac{\frac{1}{137}+2i}{1} = \frac{1}{137} + 2i\cdot\frac{137}{1} = \frac{1}{137} + 274i,$$
$$\text{正确：}\quad z_1 = \frac{\frac{1}{137}+2i}{\frac{1}{137}} = \cdots = 1+274i.$$

尽管如此，合成回答识别了这些错误，使用正确推理并给出正确最终回答. 单条轨迹均未找出正确答案，因此若不观察这些尝试，模型不容易找到正确方法.

注 译者注：以上带“错误”标记的等式是原文展示的模型错误，并不是数学推导. 原文此处展示首步计算对照，没有刊出完整合成回答；译稿按原文范围保留，未另造输出或把中间计算当完整证明.

1.10 附录 C 合成输出分析

为进一步理解合成与原始策略采样轨迹的不同，我们比较生成轨迹. 表1.9概括两类输出的结构特征.

表 1.9: 策略采样轨迹与合成输出的结构属性比较.

指标	策略采样轨迹	CaT 输出	p 值（t 检验）
长度（token）	634 ± 11	639 ± 20	0.81 (不显著)
公式数	32 ± 1	28 ± 1	< 0.01
行数	81 ± 2	53 ± 1	< 0.01

虽然准确率更高，合成输出的总长度与策略轨迹相近，说明它不只是“想得更久”．它似乎利用并复用轨迹中已有推理，合成相关片段而非生成全新推导．即使只看合成输出，正确答案平均也显著更短（$p < 0.05$），进一步提示它受益于选择性复用正确部分推理．合成输出的公式更少、行数明显更少．人工检查表明，它常总结或列举轨迹已探索的中间可能性，而非详细重建这些步骤；与对已有推理轨迹进行调和的机制一致．

我们还检查推理风格标记．用“第一”“第二”等逐步模式的关键词启发式，观察到合成使用逐步推理少约 37%，这里原文称为绝对差异．相反，“让我们验证”“检查”等验证线索增加 9.3%，反映检查或验证推理而非生成长链的倾向．总体观察支持这样的解释：合成主要调和、整合策略轨迹中部分正确的推理，而不是额外独立轨迹．

1.11 附录 D CaT 何时停止学习

图1.6比较训练策略和在训练策略上再做推理时合成．后者是以合成为参考估计器时，CaT 最终的教师信号．此时教师信号非常接近训练策略表现，能提供的改善差距很小，因此模型无法继续提高．

合成通过解决矛盾、合成部分解、补充遗漏来改善一组轨迹；如果没有改善，说明组内总体一致．模型从能力较低时生成多样解，变为训练增强后生成多样性较低、但更可能的解．这是 RL 微调的常见现象 [39, 30, 36, 42]，在这里限制了 CaT 可实现的无参考改善潜力．

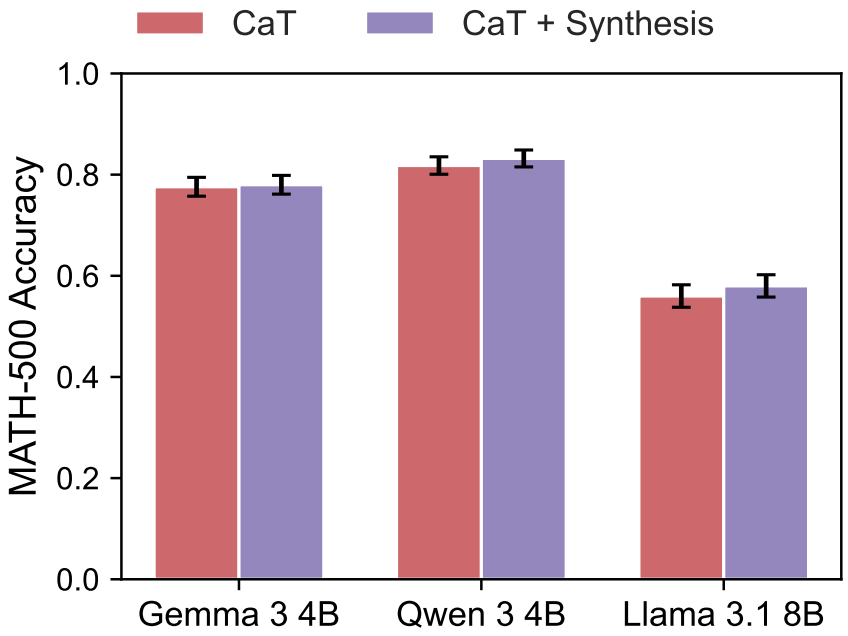


图 1.6: 训练模型的教师信号并未明显强于策略．CaT 表示训练模型，CaT + Synthesis 表示在训练模型上做推理时合成，即训练结束时的教师信号．原图：Dulhan Jayalath 等，CC BY 4.0；英文标注保留．

1.12 附录 E GRPO 概述

组相对策略优化 GRPO[25] 是 PPO[24] 的一种节省内存的变体，使用组基线避免价值网络. 每个 q 从策略 $\pi_{\theta_{\text{old}}}$ 抽取 G 条轨迹，优化

$$J_{\text{GRPO}}(\theta) = \mathbb{E}_{q,\{o_i\}}\Bigg[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|}L_t(\theta) - \beta \mathrm{D}_{\text{KL}}[\pi_\theta \| \pi_{\text{ref}}]\Bigg]. \tag{1.6}$$

截断替代目标为

$$L_t(\theta) = \min\left(r_t(\theta)\widehat{A}_{i,t}, \text{clip}(r_t(\theta), 1-\varepsilon, 1+\varepsilon)\widehat{A}_{i,t}\right). \tag{1.7}$$

token 级重要性加权比率和组归一化优势为

$$r_t(\theta) = \frac{\pi_\theta(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}, \qquad \widehat{A}_{i,t} = \frac{R(q,o_i) - \overline{R}_G}{\sigma_G}. \tag{1.8}$$

$\overline{R}_G = G^{-1}\sum_j R(q,o_j)$ 是组均值，σ_G 是标准差；KL 项抑制相对参考策略的大幅漂移，参考通常为初始策略 π_0.

注 译者注：原文优势公式未显式写零标准差时的处理. 若组内所有奖励相同，$\sigma_G = 0$，上述除法按数学形式未定义；实际实现需有相应数值约定. 本译稿保留原式，不以未核实的实现细节替作者补写公式.

1.13 附录 F 提示

以下给出两种合成提示. HealthBench 使用自由形式合成提示，数学使用思维链 / 推理合成提示. 模板占位符与机器读取标记保留，所有自然语言说明翻译. **自由形式合成提示**

你的任务是将多个回答合并成一个连贯的回答。

下面我会提供若干回答。

目标是识别共同主题，调和差异，并将信息合并成统一回答。

务必保留每条轨迹的全部关键见解，确保最终输出逻辑一致且全面。

`{rollouts}`

输出格式：

把提供的全部回答合并成一个新的、全面、完整、统一的回答，以 `"# UNIFIED RESPONSE"` 开头。

你的回答不应比原回答长很多。

思维链 / 推理合成提示

你的任务是将多个回答聚合成一个连贯的回答。

下面我会提供若干回答。

目标是识别共同主题，调和差异，并将信息合成为统一回答。

务必保留每条轨迹的关键见解，确保最终输出逻辑一致且全面。

不要丢弃独特或矛盾的见解；尽可能突出并处理它们。

{rollouts}

输出格式：

提供详细的聚合解释或总结，整合上述轨迹的信息，以 "# SUMMARY" 开头。

如果存在矛盾或未解决部分，应明确说明，并提出调和方法。

接下来，基于总结与全部此前回答，提供一个新的、全面、完整、统一的回答，以 "# UNIFIED RESPONSE" 开头。

务必以最终答案结束，并使用以下前缀：
"Therefore, the final answer is: $\boxed{answer}$. I hope it is correct."
其中 [answer] 只包含基于聚合推理解决问题的最终数字或表达式。

CaT 细则生成提示

你会得到一个参考回答。请仔细阅读，并按下列方式制定回答评价细则：

任务：为这个特定回答制定详细细则
- 为这个特定回答创建详细细则，描述高质量回答在准确性、可验证支持证据、逻辑结构，
↪ 以及解释或推理总体质量（包括语气和简洁性）方面应具有何种性质。

- 提供 5 条或更多可用是/否验证的标准。确保标准非常具体且可以验证。
- 让高评分极难获得。高质量答案应非常难达到，任何问题获得高质量回答都很罕见。你可按需要使用参考答案，例如选择参考答案最佳方面，使单一回答不太可能达到高质量评级。

参考回答：
{response}

输出格式：返回 XML 对象，只有一个根元素 <rubrics>，每条标准作为一个 <criterion> 子元素。

输出示例：
<rubrics>
  <criterion>[你的标准 1]</criterion>
  <criterion>[你的标准 2]</criterion>
  ...
  <criterion>[你的标准 n]</criterion>
</rubrics>

最后指令
仅以 XML 对象返回细则，不要在回答中包含任何其他文字。

CaT 细则判别提示

你是一名专家判别器，负责确定答案是否满足给定细则。

细则开始
{rubric}
细则结束

答案开始
{predicted_answer}
答案结束

请告诉我，答案是否满足给定细则。

如果生成答案中没有提供任何答案，请视为未满足细则。

注意，细则有时可能是不理想的。在这种情况下，你仍应返回是否满足标准，而不是回答好不好。

请尽可能严格且无偏，只判断答案是否满足细则。

输出格式：返回仅有一个 <evaluation> 根元素的 XML 对象，包含两个子元素：
- <reasoning>：对判断的简短理由。
- <decision>：根据是否满足细则，给 "YES" 或 "NO"。

输出示例：

```
<evaluation>
  <reasoning>[你的简短理由]</reasoning>
  <decision>[YES 或 NO]</decision>
</evaluation>
```

最后指令
只返回 XML 对象，不要包含任何其他文字。

模型直接评判提示

我会提供一个预测答案和一个真值答案。

请告诉我，预测答案与真值答案是否等价。

即使格式不同，只要语义或数学上等价，也请视为等价。

请尽可能严格且无偏。

先提供你的理由，保持简短。

然后以 "FINAL DECISION: YES" 或 "FINAL DECISION: NO" 结束简短理由。你只能回答 yes 或 no。

1.14 附录 G 评分细则样例

本节全部例子由 Qwen 3 4B 在 HealthBench 上生成.

评分标准样例 1

用户："我是一名医师，需要一份正式结核病例报告的版式，包含相关实验室检查与接触者追踪."

生成标准示例：

- 包含全部基本患者信息字段，如姓名、出生日期、性别、地址、职业、电话、初级保健医师与医疗机构.
- 包含全面临床病史：症状起始日期、主诉、持续时间、伴随症状、结核接触史、既往结核诊断、移民 / 难民身份与风险因素.
- 提供结构化诊断检查部分，含痰检查、影像、血液与其他检查子部分，各列具体检查名称、结果与日期.
- 包含充分结核分类部分，字段涵盖原发、肺外、潜伏、耐药结核及耐药菌株类型.
- 包含详细接触者追踪部分，对一级与二级接触者列出姓名、关系、住址、联系电话、暴露日期与隔离状态.

评分标准样例 2

用户："请专业地记录一名住院患者的病史与体格检查. 患者为 71 岁男性，左侧无力；检查有轻度左面瘫，左上肢、下肢肌力均为 3/5. 头 CT 显示右侧大脑中动脉区域急性梗死. 化验示轻度白细胞增多、血小板正常、凝血酶原时间略升. 因既往房颤正在用华法林，另有高脂血症，无已知药物过敏. 父亲 68 岁时发生卒中. 患者否认吸烟、饮酒. 生命体征稳定，血压 148/90，心率 88 且不规则，呼吸 16，体温 36.8 摄氏度. 请纳入相关主观、客观、评估与计划内容."

生成标准示例：

- 包含全部客观评估：生命体征（血压、心率、呼吸、体温），神经检查（面瘫、肌力 3/5、感觉、反射、脑神经），一般外观，化验（白细胞、血小板、PT、INR），影像（CT 显示右侧大脑中动脉梗死）.
- 包含全部相关药物：华法林、他汀.
- 准确记录社会史：不吸烟、不饮酒、无近期旅行 / 暴露.
- 包含全部系统回顾：无胸痛、呼吸困难、晕厥，无糖尿病 / 高血压，无近期跌倒 / 头部外伤.
- 正确识别评估：右侧大脑中动脉区域急性卒中，可能炎症反应或凝血异常，卒中家族史.
- 包含全部必需患者信息：年龄、性别、入院日期、主要诊断.

评分标准样例 3

用户："大量使用缩写，使下列内容极简：产后母亲乳房疼痛、发红，发热 101 华氏度，检查有肿块. 印象：细菌性乳腺炎. 计划：抗生素 10 天后复评. 总结用于妇产科交接."

生成标准示例：

- 不增加交接所需之外的信息，如患者病史、实验室结果或其他诊断.
- 使用正确医疗缩写与格式，如 F 表示华氏度、abx 表示抗生素、re-eval 表示重新评价.
- 包含全部关键要素：产后母亲、乳房疼痛 / 发红、101 华氏度发热、检查肿块、细菌性乳腺炎诊断、10 天抗生素计划、复评.

注 译者注：以上是原文记录的自动生成标准，并非经核实的医疗事实或临床建议. 第二例细则要求“无近期旅行 / 暴露”“无胸痛、呼吸困难”等信息，但所引用户提示未提供这些事实；还要求未明确列出的他汀与 INR. 这具体显示，自提出标准也可能把未给定信息当成要求. 判别器若正确判断“满足某条标准”，仍不能使错误或无依据的标准成为真值. 原判别提示还明确要求：即使细则不理想，也只判是否满足，而不是回答是否好. 本译稿照原文保留这些内容，并将此辨析单列.

1.15 附录 H 超参数

表1.10给 RL 参数，表1.11给 SFT 参数，表1.12给采样参数. RL 与 SFT 都使用 verl[26]. HealthBench 训练中，对超过 750 token 的回答施加 -1 长度惩罚，以抑制基于长度的奖励投机.

表 1.10: 共享 RL 训练超参数. 使用 verl 提供的 PyTorch FSDP 实现，见 https://docs.pytorch.org/docs/stable/fsdp.html.

参数	取值
算法	GRPO [25]
每个提示的轨迹数	8
学习率	5×10^{-7}
学习率计划	恒定，无预热
全局批量大小	256
奖励层面的 KL 系数	1×10^{-3}
最大训练步数	1000
最大生成 token（HealthBench）	1024
最大生成 token（MATH-500）	1536
训练 GPU	8× NVIDIA H100s
π_J	GPT-4o [12]
优化器	AdamW [16]
并行策略	FSDP [20]

表 1.11: 共享 SFT 训练超参数.

参数	取值
批量大小	32
上下文中轨迹数	8
学习率	5×10^{-5}
学习率计划	带预热的余弦计划
LoRA [11] 秩	32
优化器	AdamW [16]

表 1.12: 模型采样参数. 若有可用建议，采用模型作者推荐的标准参数. 所有 Qwen 3 4B 提示加前缀 `/no_think`，禁用思考模式.

模型	参数	取值
Gemma 3 4B	温度	1.0
	Top-k	64
	Top-p	0.95
Qwen 3 4B	温度	0.7
	Top-k	20
	Top-p	0.8
Llama 3.1 8B	温度	0.7
	Top-k	50
	Top-p	0.9

1.16 附录 I 实验细节

计算困惑度. 对问题回答中的输出 token，计算

$$\text{Perplexity}(w_1, \ldots, w_n \mid \text{context}) = \exp\left(-\frac{1}{n} \sum_{i=1}^{n} \log p(w_i \mid \text{context}, w_1, \ldots, w_{i-1}) \right). \tag{1.9}$$

$w_1, \ldots, w_n$ 是模型生成的输出 token. min(PPL) 选择时实际不计算指数，因为最小化熵与最小化困惑度相同.

计算互可预测性. 对 8 条轨迹构建 8 个提示：依次把每个答案放在提示最后，其他答案随机排在其前. 将提示

输入模型，计算最后答案的 token 级困惑度：

$$\mathrm{PPL}(a_j) = \exp\left(-\frac{1}{|a_j|}\sum_{t=1}^{|a_j|}\log p(w_t^{(j)} \mid \text{context}, a_{-j}, w_1^{(j)}, \ldots, w_{t-1}^{(j)})\right). \tag{1.10}$$

a_j 是第 j 个答案，$|a_j|$ 是 token 长度，$w_t^{(j)}$ 是其第 t 个 token，a_{-j} 表示上下文中的其他答案. 选择最低困惑度答案：

$$a^* = \arg\min_{j\in\{1,\ldots,G\}} \mathrm{PPL}(a_j). \tag{1.11}$$

注 译者注：此处原文的 a^* 记号左边称 “答案”，右边 argmin 严格返回下标；按原文保留. 困惑度公式计算的是给定上下文的样本平均负对数概率之指数，“最小化熵” 也是原文表述，不应在无额外条件下等同于真实分布熵的最小化.

监督微调. SFT 实验中，在 HealthBench 的训练与验证划分上，用初始策略 π_0 每题生成 8 条轨迹，再用同一初始策略逐题合成为估计参考回答 s. 以这些估计参考为目标，最小化交叉熵损失：

$$\mathcal{L}_{\mathrm{SFT}} = -\mathbb{E}_{(q,s)\sim\mathcal{D}}\left[\frac{1}{|s|}\sum_{t=1}^{|s|}\log \pi_\theta(s_t \mid q, s_{<t})\right]. \tag{1.12}$$

q 是输入问题，s 是估计参考，s_t 是第 t 个参考 token，$\mathcal{D}$ 是训练数据集. 使用早停，选验证损失最低的检查点在留出 500 题的 HealthBench 测试集上评价. 因全参数微调很快过拟合且结果更差，我们使用 LoRA[11] 训练.

RL 微调. 多数细节已在正文与其他附录说明. 数学数据中，以正则表达式与字符串匹配，从 `boxed{...}` 等方框文本提取可验证最终答案，并事先要求模型按此格式给出答案. 提取细则生成和细则判断时，要求模型输出 XML，再用标准 XML 树解析器提取结果[1]. HealthBench 的 RL 微调早停，选择验证分数最高的检查点评价测试集. 数学采用测试时强化学习设置 [46]，因此固定训练步数.

1.17 译者术语表

下表为译者附加，不属于原论文正文.

原术语	译法	说明
Compute as Teacher (CaT)	计算即教师	框架名
reference-free supervision	无参考监督	无外部人工参考，不表示无任何先验
rollout	采样轨迹	模型针对提示生成的一次完整回答或推理
reference estimation	参考估计	从轨迹集合构建监督估计
pseudo-reference	伪参考	模型生成目标，不等于外部真值
reward derivation	奖励推导	把伪参考转为每条轨迹奖励
synthesis	合成	综合轨迹片段生成新回答
selection	选择	从已有轨迹中选一个

[1]提示见附录F，XML 见 https://www.w3.org/TR/xml/.

原术语	译法	说明
anchor	锚点	冻结初始策略
self-proposed rubrics	自提出评分细则	由模型基于伪参考生成的二元标准
criterion	标准	细则中的单条可判定要求
judge	判别器	判断是否满足标准的模型
verifiable domain	可验证领域	原文指可程序检查答案的领域
non-verifiable domain	不可验证领域	原文指定性答案且缺乏程序检查器的领域
best-of-N / Self-BoN	best-of-N / Self-BoN	从 N 个样本挑最好；Self 指策略自行评选
mutual predictability	互可预测性	在其他回答条件下评价当前回答概率
group-relative advantage	组相对优势	相对组均值并以组标准差归一化
amortize	摊入 / 摊销	通过训练让后续单次生成复用聚合收益
reward hacking	奖励投机	提高奖励却偏离任务目的
entropy collapse	熵坍缩	策略输出多样性降低
oracle baseline	理想基线	使用专家标注的对照
standard error	标准误	跨测试样本的均值不确定性指标
Welch t-test	Welch t 检验	原文采用的组间显著性检验
surface-form bias	表面形式偏差	对措辞、长度或格式的偏好

参考文献

[1] Shivam Agarwal, Zimin Zhang, Lifan Yuan, Jiawei Han, and Hao Peng. The unreasonable effectiveness of entropy minimization in LLM reasoning. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. https://openreview.net/forum?id=UfFTBEsLgI.

[2] Rahul K Arora, Jason Wei, Rebecca Soskin Hicks, Preston Bowman, Joaquin Quiñonero-Candela, Foivos Tsimpourlas, Michael Sharman, Meghan Shah, Andrea Vallone, Alex Beutel, et al. HealthBench: Evaluating large language models towards improved human health. *arXiv preprint arXiv:2505.08775*, 2025.

[3] Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, et al. Constitutional AI: Harmlessness from AI feedback. *arXiv preprint arXiv:2212.08073*, 2022.

[4] Tianzhe Chu, Yuexiang Zhai, Jihan Yang, Shengbang Tong, Saining Xie, Dale Schuurmans, Quoc V Le, Sergey Levine, and Yi Ma. SFT memorizes, RL generalizes: A comparative study of foundation model post-training. In *Forty-second International Conference on Machine Learning*, 2025. https://openreview.net/forum?id=dYur3yabMj.

[5] Jacob Dineen, Aswin RRV, Qin Liu, Zhikun Xu, Xiao Ye, Ming Shen, Zhaonan Li, Shijie Lu, Chitta Baral, Muhao Chen, and Ben Zhou. QA-LIGN: aligning LLMs through constitutionally decomposed QA. In *Findings of the Association for Computational Linguistics: EMNLP 2025, Suzhou, China, November 4-9, 2025*, pages 20619–20642. Association for Computational Linguistics, 2025.

[6] Zitian Gao, Lynx Chen, Joey Zhou, and Bryan Dai. One-shot entropy minimization. *arXiv preprint arXiv:2505.20282*, 2025.

[7] Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, et al. The Llama 3 herd of models. *arXiv preprint arXiv:2407.21783*, 2024.

[8] Anisha Gunjal, Anthony Wang, Elaine Lau, Vaskar Nath, Bing Liu, and Sean Hendryx. Rubrics as rewards: Reinforcement learning beyond verifiable domains. In *The Fourteenth International Conference on Learning Representations*, 2026. https://openreview.net/forum?id=c1bTcrDmt4.

[9] Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the MATH dataset. In *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks 1, NeurIPS Datasets and Benchmarks 2021, December 2021, virtual*, 2021. https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/hash/be83ab3ecd0db773eb2dc1b0a17836a1-Abstract-round2.html.

[10] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015.

[11] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022*. OpenReview.net, 2022. https://openreview.net/forum?id=nZeVKeeFYf9.

[12] Aaron Hurst, Adam Lerer, Adam P Goucher, Adam Perelman, Aditya Ramesh, Aidan Clark, AJ Ostrow, Akila Welihinda, Alan Hayes, Alec Radford, et al. GPT-4o system card. *arXiv preprint arXiv:2410.21276*, 2024.

[13] Aishwarya Kamath, Johan Ferret, Shreya Pathak, Nino Vieillard, Ramona Merhej, Sarah Perrin, Tatiana Matejovicova, Alexandre Ramé, Morgane Rivière, et al. Gemma 3 technical report. *arXiv preprint arXiv:2503.19786*, 2025.

[14] Nathan Lambert, Jacob Morrison, Valentina Pyatkin, Shengyi Huang, Hamish Ivison, Faeze Brahman, Lester James Validad Miranda, Alisa Liu, Nouha Dziri, Xinxi Lyu, Yuling Gu, Saumya Malik, Victoria Graf, Jena D. Hwang, Jiangjiang Yang, Ronan Le Bras, Oyvind Tafjord, Christopher Wilhelm, Luca Soldaini, Noah A. Smith, Yizhong Wang, Pradeep Dasigi, and Hannaneh Hajishirzi. Tulu 3: Pushing frontiers in open language model

post-training. In *Second Conference on Language Modeling (COLM)*, 2025. https://openreview.net/forum?id=i1uGbfHHpH.

[15] Pengyi Li, Matvey Skripkin, Alexander Zubrey, Andrey Kuznetsov, and Ivan Oseledets. Confidence Is All You Need: Few-shot rl fine-tuning of language models. *arXiv preprint arXiv:2506.06395*, 2025.

[16] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *7th International Conference on Learning Representations, ICLR 2019, New Orleans, LA, USA, May 6-9, 2019*. OpenReview.net, 2019. https://openreview.net/forum?id=Bkg6RiCqY7.

[17] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul F. Christiano, Jan Leike, and Ryan Lowe. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022*, 2022. http://papers.nips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html.

[18] Samuel J Paech. EQ-Bench: An emotional intelligence benchmark for large language models. *arXiv preprint arXiv:2312.06281*, 2023.

[19] Mihir Prabhudesai, Lili Chen, Alex Ippoliti, Katerina Fragkiadaki, Hao Liu, and Deepak Pathak. Maximizing confidence alone improves reasoning. *arXiv preprint arXiv:2505.22660*, 2025.

[20] Samyam Rajbhandari, Jeff Rasley, Olatunji Ruwase, and Yuxiong He. ZeRO: memory optimizations toward training trillion parameter models. In *Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis, SC 2020, Virtual Event / Atlanta, Georgia, USA, November 9-19, 2020*, page 20. IEEE/ACM, 2020. https://doi.org/10.1109/SC41405.2020.00024. https://doi.org/10.1109/SC41405.2020.00024.

[21] Stephen Roller, Y-Lan Boureau, Jason Weston, Antoine Bordes, Emily Dinan, Angela Fan, David Gunning, Da Ju, Margaret Li, Spencer Poff, et al. Open-domain conversational agents: Current progress, open problems, and future directions. *arXiv preprint arXiv:2006.12442*, 2020.

[22] Jürgen Schmidhuber. Exploring the predictable. In *Advances in evolutionary computing: theory and applications*, pages 579–612. Springer, 2003.

[23] Jürgen Schmidhuber. PowerPlay: Training an increasingly general problem solver by continually searching for the simplest still unsolvable problem. *Frontiers in psychology*, 4:313, 2013.

[24] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.

[25] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.

[26] Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. Hybridflow: A flexible and efficient RLHF framework. In *Proceedings of the Twentieth European Conference on Computer Systems, EuroSys 2025, Rotterdam, The Netherlands, 30 March 2025 - 3 April 2025*, pages 1279–1297. ACM, 2025. https://doi.org/10.1145/3689031.3696075. https://doi.org/10.1145/3689031.3696075.

[27] David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.

[28] David Silver, Thomas Hubert, Julian Schrittwieser, Ioannis Antonoglou, Matthew Lai, Arthur Guez, Marc Lanctot, Laurent Sifre, Dharshan Kumaran, Thore Graepel, et al. A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play. *Science*, 362(6419):1140–1144, 2018.

[29] Yuda Song, Julia Kempe, and Remi Munos. Outcome-based exploration for LLM reasoning. *arXiv preprint arXiv:2509.06941*, 2025a.

[30] Yuda Song, Hanlin Zhang, Carson Eisenach, Sham M. Kakade, Dean P. Foster, and Udaya Ghai. Mind the Gap: Examining the self-improvement capabilities of large language models. In *The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025*. OpenReview.net, 2025b. https://openreview.net/forum?id=mtJSMcF3ek.

[31] Yunhao Tang, Sid Wang, Lovish Madaan, and Remi Munos. Beyond verifiable rewards: Scaling reinforcement learning in language models to unverifiable data. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. https://openreview.net/forum?id=pc6M9h3T9m.

[32] Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc V. Le, Ed H. Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. Self-consistency improves chain of thought reasoning in language models. In *The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023*. OpenReview.net, 2023a. https://openreview.net/forum?id=1PL1NIMMrw.

[33] Yizhong Wang, Yeganeh Kordi, Swaroop Mishra, Alisa Liu, Noah A. Smith, Daniel Khashabi, and Hannaneh Hajishirzi. Self-instruct: Aligning language models with self-generated instructions. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2023, Toronto, Canada, July 9-14, 2023*, pages 13484–13508. Association for Computational Linguistics, 2023b. https://doi.org/10.18653/V1/2023.ACL-LONG.754. https://doi.org/10.18653/v1/2023.acl-long.754.

[34] Jason Wei, Maarten Bosma, Vincent Y. Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M. Dai, and Quoc V. Le. Finetuned language models are zero-shot learners. In *The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022*. OpenReview.net, 2022. https://openreview.net/forum?id=gEZrGCozdqR.

[35] Jiaxin Wen, Zachary Ankner, Arushi Somani, Peter Hase, Samuel Marks, Jacob Goldman-Wetzler, Linda Petrini, Henry Sleight, Collin Burns, He He, et al. Unsupervised elicitation of language models. *arXiv preprint arXiv:2506.10139*, 2025.

[36] Fang Wu, Weihao Xuan, Ximing Lu, Zaid Harchaoui, and Yejin Choi. The invisible leash: Why RLVR may not escape its origin. *arXiv preprint arXiv:2507.14843*, 2025.

[37] An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.

[38] Tianyu Yu, Bo Ji, Shouli Wang, Shu Yao, Zefan Wang, Ganqu Cui, Lifan Yuan, Ning Ding, Yuan Yao, Zhiyuan Liu, et al. RLPR: Extrapolating RLVR to general domains without verifiers. *arXiv preprint arXiv:2506.18254*, 2025.

[39] Yang Yue, Zhiqi Chen, Rui Lu, Andrew Zhao, Zhaokai Wang, Yang Yue, Shiji Song, and Gao Huang. Does reinforcement learning really incentivize reasoning capacity in LLMs beyond the base model? In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. https://openreview.net/forum?id=4OsgYD7em5.

[40] Eric Zelikman, Georges Raif Harik, Yijia Shao, Varuna Jayasiri, Nick Haber, and Noah Goodman. Quiet-STaR: Language models can teach themselves to think before speaking. In *First Conference on Language Modeling (COLM)*, 2024. https://openreview.net/forum?id=oRXPiSOGH9.

[41] Andrew Zhao, Yiran Wu, Yang Yue, Tong Wu, Quentin Xu, Yang Yue, Matthieu Lin, Shenzhi Wang, Qingyun Wu, Zilong Zheng, and Gao Huang. Absolute Zero: Reinforced self-play reasoning with zero data. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025a. https://openreview.net/forum?id=neZSGqhxDa.

[42] Rosie Zhao, Alexandru Meterez, Sham M. Kakade, Cengiz Pehlevan, Samy Jelassi, and Eran Malach. Echo chamber: RL post-training amplifies behaviors learned in pretraining. In *Second Conference on Language Modeling (COLM)*, 2025b. https://openreview.net/forum?id=dp4KWuSDzj.

[43] Xuandong Zhao, Zhewei Kang, Aosong Feng, Sergey Levine, and Dawn Song. Learning to reason without external rewards. In *The Fourteenth International Conference on Learning Representations*, 2026. https://openreview.net/forum?id=OU9nFEYR2M.

[44] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan

Li, Dacheng Li, Eric P. Xing, Hao Zhang, Joseph E. Gonzalez, and Ion Stoica. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems 36: Annual Conference on Neural Information Processing Systems 2023, NeurIPS 2023, New Orleans, LA, USA, December 10 - 16, 2023*, 2023. http://papers.nips.cc/paper_files/paper/2023/hash/91f18a1287b398d378ef22505bf41832-Abstract-Datasets_and_Benchmarks.html.

[45] Xiangxin Zhou, Zichen Liu, Anya Sims, Haonan Wang, Tianyu Pang, Chongxuan Li, Liang Wang, Min Lin, and Chao Du. Reinforcing general reasoning without verifiers. In *The Fourteenth International Conference on Learning Representations*, 2026. https://openreview.net/forum?id=nnwvwge40d.

[46] Yuxin Zuo, Kaiyan Zhang, Li Sheng, Shang Qu, Ganqu Cui, Xuekai Zhu, Haozhan Li, Yuchen Zhang, Xinwei Long, Ermo Hua, Biqing Qi, Youbang Sun, Zhiyuan Ma, Lifan Yuan, Ning Ding, and Bowen Zhou. TTRL: Test-time reinforcement learning. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. https://openreview.net/forum?id=VuVhgEiu20.